MANUAL DE USUARIO / PROYECTO 02

Duplicate & Fraud Risk Detector

Automatización de pruebas de duplicidad, conciliación y priorización de riesgos en el ciclo de compras.

Informe reproducible · Python + Excel · Sociedad Ficticia X, S.L.

2.239 Facturas analizadas	427 Pedidos de compra
35 Casos de revisión	11 Pares sospechosos

Advertencia: el análisis identifica señales de revisión. No constituye una conclusión de fraude, una prueba de pago duplicado ni un dictamen de auditoría.

Edición 2.0 · Universo simulado 2026 · Elaborado con 4 bases de datos ficticias entrelazadas.

01 / Preparación y ejecución

El paquete ZIP contiene los cuatro Excel ficticios, el motor Python, el libro Excel ya generado, la matriz de controles, la batería de pruebas y este manual.

1.1. Estructura del paquete

Carpeta / archivo	Función
fraud_detector.py	Programa principal: normaliza, identifica casos y exporta el reporte.
src/source_reader.py	Lectura de los archivos de entrada y normalización de fechas, importes y referencias.
inputs/X_DEMO_*.xlsx	Cuatro bases sintéticas: facturas, pedidos, proyectos y CECOs.
output/DUPLICATE_RISK_2026.xlsx	Libro de auditoría generado. Se puede abrir sin Python.
output/run_summary.json	Métricas de ejecución: registros, reglas y casos.
tests/test_detector.py	Pruebas de conteos, controles, signos, relaciones y trazabilidad.
inputs/seguimiento_casos.csv	Plantilla de revisión persistente para futuras ejecuciones.

1.2. Dependencias

Requiere Python 3.11+ y el módulo artifact_tool para importar/exportar Excel. No se ha verificado que artifact_tool esté publicado para instalación pública mediante pip. Por ello, el paquete incluye el Excel final preparado para trabajar directamente. Si tu entorno no dispone de esa dependencia, no se garantiza la regeneración local del informe.

1.3. Ejecutar en un entorno compatible

Desde la carpeta raíz del proyecto:

```
python fraud_detector.py --input-dir inputs --output output/DUPLICATE_RISK_2026.xlsx
```

Para ejecutar las comprobaciones automáticas:

```
python -m unittest discover -s tests -v
```

Los ficheros fuente permanecen sin alterar durante el análisis. El programa sobrescribe el XLSX de salida si existe; guarda antes cualquier anotación manual.

02 / Navegación del Excel

El Excel no es solo un dashboard: contiene la población completa, los casos seleccionados, la explicación de cada control y la trazabilidad documental.

Hoja	Qué encontrarás
01_Dashboard	KPIs, filtro mensual, tendencia de alertas, distribución de reglas y avisos metodológicos.
02_Casos	Registro maestro con ID estable, prioridad, score, documentos, evidencia y seguimiento editable.
03_Pares	Comparación entre facturas potencialmente relacionadas, días entre fechas y similitud textual.
04_Sobrefacturacion	POs cuyo total facturado enlazado supera el pedido; importe de diferencia orientativo.
05_Facturas	Universo íntegro de facturas, estado de ERP, cantidades y casos asociados.
06_Pedidos	Universo íntegro de PO, número de facturas, atribuible y excepciones de importe.
07_Proveedores	Concentración de actividad, número de casos y exposición ilustrativa.
08_Evolucion	Actividad 2026 por mes, facturas, casos, prioridades y exceso sobre PO.
09_Controles	Diccionario de reglas, puntuación inicial y número de casos por control principal.
10_Metodologia	Criterios interpretativos, límites y condiciones de evidencia.
11_Parametros	Variables de ejecución y lista de meses del filtro.
12_Trazabilidad	Archivos de origen, recuentos y huellas digitales SHA-256.

2.1. Primer recorrido recomendado

Comienza en 01_Dashboard → selecciona un período → abre 02_Casos y filtra por prioridad → comprueba los números en 03_Pares o 04_Sobrefacturacion → revisa la población en 05_Facturas y 06_Pedidos → escribe la conclusión en el registro.

03 / Controles implementados

Cada control representa una hipótesis de revisión y se asigna al caso una regla principal; un par puede cumplir varias reglas simultáneamente.

Regla y prioridad base	Condición detectada	Comprobación propuesta
R01 · 95	Proveedor y número de factura repetidos.	Obtener originales, verificar que son el mismo documento, contabilización y posibles abonos.
R02 · 92	Proveedor, importe firmado, fecha y descripción iguales.	Contrastar número de factura, serie, impuestos, concepto y duplicidad de registro.
R03 · 74	Proveedor, fecha e importe idénticos.	Confirmar si son prestaciones distintas, facturación periódica o varias operaciones legítimas.
R04 · 64	Mismo proveedor e importe; fechas próximas y texto similar.	Comparar detalle del servicio, período de prestación y pedido/contrato subyacente.
R05 · 69	Dos facturas con la misma PO e importe próximo.	Examinar hitos, entregas parciales y cobros/facturación por etapas.
R06 · 78	Facturación identificada superior al total PO.	Inspeccionar adendas, nuevos presupuestos, abonos e imputaciones entre pedidos.
R07 · 62	Proveedor de factura difiere del de su PO.	Verificar tercero facturador, cambio de proveedor y autorización.

Ejercicio de auditoría: pregunta siempre ¿qué puede estar mal?, ¿qué afirmación contable afecta?, ¿qué procedimiento ejecutarías? y ¿qué evidencia sería suficiente?

3.1. Datos que faltan para concluir

Sin PDFs de las facturas, contratos, justificantes de recepción, aprobaciones, mayor de proveedores y extractos bancarios no es posible establecer pagos duplicados o fraude probado. Los campos «pagado» y «pendiente» solo reflejan el dato del archivo de compras.

04 / Score y clasificación de riesgo

La puntuación es un índice heurístico de priorización, no una probabilidad estadística de fraude. El score de cada caso parte de la regla principal (la de mayor puntuación) y suma únicamente ajustes delimitados.

Elemento	Aplicación
Puntuación inicial	R01 95, R02 92, R03 74, R04 64, R05 69, R06 78, R07 62.
Ajuste +4	Si las dos facturas comparten PO y la regla principal no es R01 ni R02.
Ajuste +2	Si ambas facturas tienen importe «pagado» informado en ERP. No prueba pago bancario.
Escala máxima	Se limita a 99 puntos para los casos emparejados.
R06 importe elevado	Puede elevarse a 88 cuando el exceso supera el 25 % de la PO.
Crítica	Score igual o superior a 90.
Alta	Score entre 72 y 89.
Media / Baja	Media entre 50 y 71. Baja inferior a 50.

4.1. Qué significa el importe de exposición

Para un par de facturas se utiliza, con fines orientativos, el menor de los importes absolutos. En sobre-facturación se utiliza la diferencia positiva entre facturado atribuible y PO. No sumes las exposiciones: una factura puede intervenir en más de un caso, y los importes brutos con IVA no representan pérdida ni ajuste contable.

4.2. Facturación parcial y abonos

Los pedidos pueden relacionarse con varias facturas. Cuando una factura cita varias POs, el motor reparte su importe entre esas referencias de forma equitativa; esta atribución es un supuesto de trabajo y debe confirmarse con documentación. Los abonos conservan el signo y no se agrupan directamente con facturas positivas por coincidencia de magnitud.

05 / Protocolo de revisión de un caso

Utiliza un criterio reproducible y documenta la evidencia, incluso cuando concluyas que la alerta era un falso positivo.

Paso	Qué debe hacer quien revisa
01 Selección	Abrir 02_Casos; filtrar prioridades Crítica o Alta. Anotar ID de caso, regla y documentos.
02 Integridad	Verificar en 05_Facturas que el registro existe y su importe coincide con el sistema fuente.
03 Comparación	En 03_Pares comprobar números, proveedor, fecha, concepto, impuestos y PO asociada.
04 Evidencia	Recabar factura original, contrato o encargo, documentación de recepción, mayor y pagos bancarios.
05 Conclusión	Indicar si es duplicado real, operación distinta justificada, reversión, error o caso no concluyente.
06 Seguimiento	Completar Estado, Responsable, Evidencia y Conclusión. Evitar sobrescribir sin guardar seguimiento.

5.1. Estados disponibles

Pendiente: aún no revisado. En investigación: se requieren soportes. Justificada: coincidencia legítima. Confirmada: incidencia documentada. Descartada: no se identifica excepción. Corregida: se ha aplicado una medida y verificado su resultado.

5.2. Mantener las conclusiones al regenerar

Para mantener revisiones, utiliza el fichero inputs/seguimiento_casos.csv (UTF-8). Debe contener estas cinco columnas exactas:

`case_id,estado,responsable,notas,evidencia`
Ejemplo de fila ficticia (sustituye por un ID real del informe):

`CAS-XXXXXXXXXX,Justificada,Revisor,Servicios distintos,Contrato_DEMO.pdf`
Para exportar automáticamente los estados y notas del Excel editado, ejecuta primero:
`python scripts/exportar_seguimiento.py`
A continuación, python fraud_detector.py recuperará las revisiones por ID desde el CSV. Si el Excel contiene casos que ya no están en la nueva población, no aparecerán en el libro regenerado.

06 / Parametrización, escenarios y pruebas

Los umbrales están expuestos como argumentos de línea de comandos. El archivo Excel 11_Parametros los muestra como documentación de la ejecución; cambiarlos en Excel no recalcula los controles.

Parámetro CLI	Por defecto	Efecto
--days	7	Máximo de días entre facturas para R04.
--min-similarity	0.86	Umbral de similitud de descripción de 0 a 1 para R04.
--threshold	1.00	Tolerancia absoluta en euros al conciliar importes / mismo importe.
--review-file	inputs/seguimiento_casos.csv	Ruta de revisión persistente.
--input-dir	inputs	Carpeta que contiene cuatro X_DEMO*.xlsx.
--output	output/DUPLICATE_RISK_2026.xlsx	Libro Excel regenerado.

6.1. Escenarios de prueba sintéticos controlados

Se han introducido artificialmente seis registros de demostración y se han ajustado otros dos, sin cambiar la estructura de los cuatro Excel. El objetivo es disponer de casos visibles de R02, R03, R04 y R05 además de las coincidencias de R01 y las desviaciones de R06 ya existentes.

R02: dos facturas con fechas, proveedor, importes y descripción iguales. R03: mismo día e importe con conceptos distintos. R04: descripciones casi idénticas separadas cinco días. R05: dos facturas vinculadas a la misma PO por el mismo importe, con explicación alternativa de facturación por hitos.

6.2. Pruebas automáticas

La carpeta tests comprueba los volúmenes de entradas, activación de reglas, unicidad y estabilidad de IDs, signo de abonos, consistencia de facturas y POs, y recuentos mensuales. Los hashes de 12_Trazabilidad ayudan a comprobar los mismos archivos fuente.

07 / Limitaciones y preguntas frecuentes

Pregunta	Respuesta operativa
¿Por qué aparecen facturas parecidas?	Una coincidencia de precio o fecha no demuestra duplicidad; pueden ser servicios periódicos o facturación por hitos.
¿Una PO con exceso es un pago duplicado?	No. Muestra desviación entre pedido y facturas enlazadas. Sin extracto bancario no prueba pago.
¿Por qué un caso tiene varias reglas?	El mismo par puede cumplir criterios simultáneos. Se crea un solo caso con todas las reglas que activaron el emparejamiento.
¿Por qué R07 tiene 0 casos?	Los datos sintéticos de este universo no presentan proveedores discordantes en las POs vinculadas.
¿Puedo sumar importes de exposición?	No; son importes orientativos no aditivos con solapamientos potenciales.
¿Puedo agregar nuevas sociedades?	La lectura acepta la estructura X_DEMO de esta sociedad; para varias entidades hay que ampliar esquema y claves intercompany.
¿Por qué puede fallar en mi Mac?	artifact_tool debe estar instalado y disponible; no se ha verificado su distribución pública. El XLSX ya generado sí puede abrirse.
¿Cómo actualizar el dashboard?	Regenera el informe con el script en entorno compatible. El selector mensual modifica KPIs dinámicos, no recalcula reglas.

7.1. Extensiones recomendadas

Con libro mayor, justificantes de pago y bancos podría incorporarse confirmación de pagos repetidos. Con PDFs y pedidos aprobados podríamos automatizar cotejo de números, cantidades y autorizaciones. Con historiales de proveedor se podría calibrar la tasa de falsos positivos.

Resultado esperado: priorizar, investigar, documentar y concluir. Nunca sustituir una revisión profesional por el score.

Este proyecto forma parte de un portfolio de auditoría automatizada, construido con datos íntegramente sintéticos y sin información identificativa de empresas o personas reales.